Разведочный анализ данных (EDA)

Часть 1. Философия EDA, первичный аудит, распределения и очистка данных

Лекция для начинающих в ML

Осень 2026

1. Философия EDA: Garbage In — Garbage Out

Говорим на одном языке:

- **Датасет** (X, y) — таблица (N объектов $\times$ D признаков).
- **Фича** (x_j) — признак объекта (например, район или число ночей).
- **Таргет** (y) — целевая переменная, которую предсказываем (`price` — цена за ночь).

Мотивационный антипример

Скормили сырой датасет в `LinearRegression().fit(X, y)` $\longrightarrow$ `ValueError: Input X contains NaN.`

Как мы оцениваем регрессию?

Функция потерь (MSE):

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Коэффициент детерминации (R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Вопрос в зал: если мы просто удалим строки с `NaN`, обучится ли модель на колонке `price`, где написано `"75.00 Rub"` и `"150 USD"`?

2. Типология данных и цена слепой очистки

Тип признака	Общий пример	Пример из NYC Airbnb
Числовой (непрерывный)	Площадь, концентрация оксидов	`price`, `latitude`, `longitude`, `reviews_per_month`
Числовой (дискретный)	Число комнат, возраст	`min_nights`, `reviews_count`, `availability_365`
Категориальный (номинальный)	Тип гаража, район города	`borough`, `neighborhood`, `room_type`
Категориальный (порядковый)	Качество отделки, стадия болезни	*Нет в сыром виде (можно извлечь из текста)*
Категориальный (бинарный)	Наличие реки, флаг ремонта	*Флаг `has_reviews` (создадим сами!)*
Временной (Datetime)	Дата продажи дома	`last_review_date`

Ловушка чисел-масок

`listing_id` и `host_id` имеют тип `int64`.
Вопрос: хост с ID = 200 000 в два раза авторитетнее хоста с ID = 100 000? Нет)) и вообще, id лучше удалять

Золотое правило чистки

Стерли спецсимволы и валюты (`regex`) → потеряли КАПС (`"!!!"`), эмодзи (🔥) и приравняли `75 Rub` к `$75`!
Сначала выжми фичи из грязи, потом чисти.

3. Первичный аудит: Проклятие размерности

Оценка `df.shape`: баланс между числом наблюдений N и количеством признаков D (у нас $45\,000 \times 16$).

Что будет, если признаков больше, чем наблюдений ($D \gg N$) или D просто огромное?

1. Взгляд через школьную алгебру

Представьте систему линейных уравнений:

$$\begin{cases} w_1 x_{11} + w_2 x_{12} + \cdots + w_D x_{1D} = y_1 \\ w_1 x_{21} + w_2 x_{22} + \cdots + w_D x_{2D} = y_2 \\ w_1 x_{31} + w_2 x_{32} + \cdots + w_D x_{3D} = y_3 \end{cases}$$

3 уравнения (N) и 100 неизвестных (D). Решений бесконечно много — модель просто **вызубрит** обучающую выборку наизусть!

2. Взгляд через геометрию векторов

Каждый объект — точка в D-мерном пространстве.

- При росте D пространство становится «пустым», а расстояния между точками — огромными.
- Признаки начинают дублировать друг друга (шум).

Как бороться? Регуляризация и отбор фичей помогают, но подробнее — позже

3. Базовая статистика (.describe()) и метрики

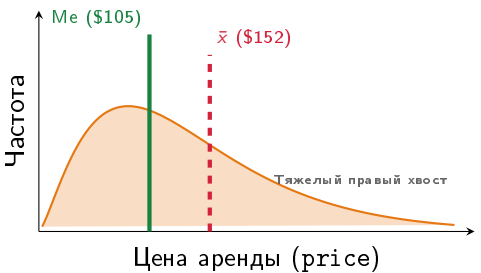
Статистика	Формула / Обозначение	Физический смысл и интерпретация
`count`	n	Количество заполненных (`non-null`) объектов (видим пропуски!).
`mean`	$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$	Среднее арифметическое («центр масс», сильно тянется за выбросами).
Дисперсия	$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$	Средний квадрат отклонения значений от среднего (разброс в квадратах единиц).
`std`	$\sigma = \sqrt{\sigma^2}$	Стандартное отклонение (типичный разброс вокруг среднего в исходных единицах).
`SE`	$SE = \frac{\sigma}{\sqrt{n}}$	Стандартная ошибка среднего (насколько точно $\bar{x}$ оценивает истинное среднее).
`min` / `max`	$\min(x)$, $\max(x)$	Экстремумы выборки. Главный детектор абсурда (price = \$0, min_nights = 1250).
`25%`, `75%`	Q_{25}, Q_{75}	Квартили: границы, ниже которых лежат 25% и 75% отсортированных данных.
`50%` (`median`)	$\text{Me} = Q_{50}$	Медиана: делит упорядоченный ряд ровно пополам. Не чувствительна к выбросам!

4. Распределения: Симметрия против «Тяжелого хвоста»

Нормальное распределение ($\bar{x} \approx$ Me)



Скос вправо / Right Skew (наш `price`)



4. Как измерить асимметрию математически?

1. Экспресс-критерий (через SE)

$$\frac{|\bar{x} - \text{Me}|}{SE} \leq 3 \iff \frac{\sqrt{n} \cdot |\bar{x} - \text{Me}|}{\sigma} \leq 3$$

Почему дает сбой на больших данных?
При $n = 45\,000$ множитель $\sqrt{n} \approx 212$ уходит в числитель и раздувает показатель даже при микроскопическом отклонении!

2. Коэффициент асимметрии (Skewness)

$$\text{Skew} = \frac{1}{n} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{\sigma} \right)^3$$

Разбор на пальцах:

- $\frac{x_i - \bar{x}}{\sigma}$ — **Z-масштабирование**!
- **Куб** $(\dots)^3$**:** сохраняет знак хвоста ($+$ правый, $-$ левый) и взрывает выбросы ($10\sigma \to 10^3 = 1000$).

Шкала интерпретации: $|\text{Skew}| \leq 0.5$ — симметрия (норма) , $0.5 < |\text{Skew}| \leq 1$ — умеренный скос , $|\text{Skew}| > 1$ — нужен логарифм!

4. Логарифмическая трансформация log1p

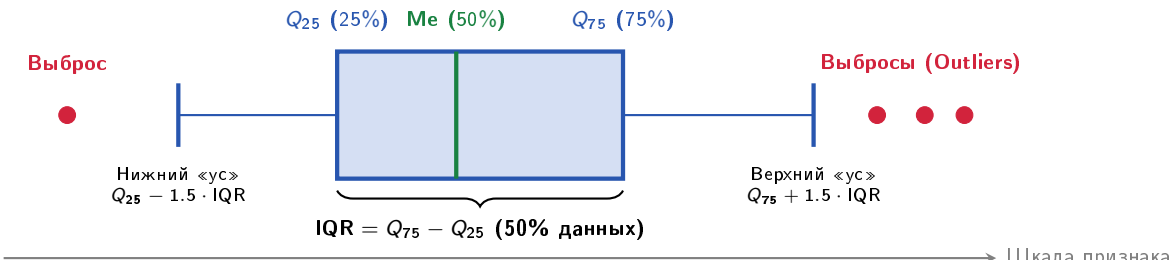
Формула безопасного логарифма

$$\log1p(p) = \ln(1 + p)$$

Три причины, почему это работает идеально:

1. **Защита от нуля:** Если признак равен 0 (например, 0 отзывов), обычный $\ln(0) = -\infty$ уронит код, а $\ln(1 + 0) = 0$.
2. **Спасение линейной регрессии (MSE):** Линейка минимизирует $\frac{1}{n}\sum(y_i - \hat{y}_i)^2$. На сыром таргете ошибка на квартире за \$10 000 возведется в квадрат, улетит в космос и сломает все веса модели. Первоочерёдно дело в выбросах, которые логарифм уменьшает.
3. **Психология восприятия цен:** Разница между \$50 и \$100 за ночь — двукратный скачок класса жилья, а между \$5 000 и \$5 050 — незаметная мелочь. Логарифм переводит *кратную* разницу в *линейную*!

5. Выбросы: Анатомия Boxplot («Ящик с усами»)



Усики всегда цепляются за минимальный и максимальный элемент на отрезке $[Q_{25} - 1.5 \cdot \mathrm{IQR};\ \ Q_{75} + 1.5 \cdot \mathrm{IQR}]$.

5. Выбросы: Природа, Критерии и Методы борьбы

Природа аномалий: Технические ошибки ввода / сбои (`min_nights = 1250`) vs Редкие реальные объекты.

Математические критерии фильтрации

1. Межквартильное правило Тьюки:

$$x \in [Q_{25} - 1.5 \cdot \text{IQR};\quad Q_{75} + 1.5 \cdot \text{IQR}]$$

2. Правило сигм (3σ и 5σ):

- $\bar{x} \pm 3\sigma$ — для симметричных («колокол»).
- $\bar{x} \pm 5\sigma$ — для скошенных распределений.

Методы обработки

1. **Удаление строк (Drop)** — если уверены, что это мусор.
2. **Клиппинг (Winsorizing)** — стягивание экстремумов к точным границам «усов».

Вопрос: как без звонка хозяину понять, ошибка это или реальный дворец? (Здравый смысл + соседние колонки!)

5. Битва стратегий: логарифм vs удаление

А есть ли разница: сначала залогарифмировать или сначала удалить выбросы?

Вариант 1: Сначала удалить ⟶ потом `log1p`

Цель: Убрать истинные технические ошибки и баги ввода (ошиблись нулем, вбили бронь на 1000 ночей вместо 10).

Почему нельзя наоборот?
Логарифм сильно сожмет шкалу и **«спрячет» ошибку** среди нормальных данных — фильтры выбросов её просто не заметят!

Вариант 2: Сначала `log1p` ⟶ потом удалить

Цель: Сохранить реальную бизнес-информацию о люкс-сегменте (пентхаусы за $10 000 реально существуют!), но «успокоить» модель.

Как это работает?
Логарифм аккуратно подтянет тяжелый правый хвост к центру, а фильтр отсечет только то, что дико даже в лог-шкале.

6. Пропущенные значения (NaN): Ошибка или Закономерность?

Поиск масштаба бедствия: `df.isna().sum()`. **Критично понять природу пропуска до заполнения.**

1. Случайный сбой (Ошибка)

Датчик моргнул, потерялся пакет GPS на трассе.

Что делать?

- Удалить строку/столбец (если мало/много).
- Заполнить статистикой: **медиана**, среднее, мода.
- **Интерполяция** по соседним точкам (например, скорость машины по соседним секундам).

2. Структурный пропуск (Выгода!)

Объекта физически не существует (например, в доме нет подвала → площадь подвала `NaN`).

Кейс Airbnb (`reviews_per_month`):
Пропущено $> 20\%$ строк! Но у всех них `reviews_count == 0`.
Здесь `NaN` — это не неизвестность, а реальный `0`! Заполняем нулем и создаем бинарный флаг.

6. Главный грех в ML: Утечка данных (Data Leakage)

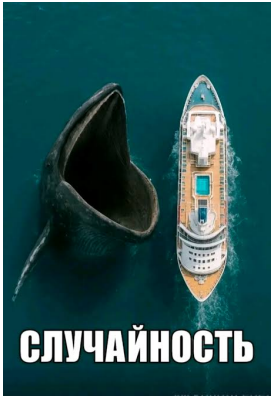
Утечка данных — ситуация, когда информация из тестовой выборки или «будущего» просачивается в обучение.

Золотое правило гигиены пайплайна

Разбиение `train_test_split` делается **ДО** вычисления любых статистик!
Медиану и среднее считаем **только на** `Train` и применяем к `Test`.

Три классических вида утечек:

1. **Временна́я:** случайное перемешивание вместо честного сплита «прошлое → будущее».
2. **Дубликаты:** попадание строк-клонов и в `Train`, и в `Test`.
3. **Функциональная зависимость:** **log_price** и **price**.



В нашем случае мы СЛУЧАЙНО оставили price внутри X и радуемся повышению метрики

Спасибо за внимание!

Вопросы? • Обсуждение

В СЛЕДУЮЩИЙ РАЗ...

Мы снимем мантию хаоса с данных и разберем:

- **Feature Engineering:** как создавать сильные признаки своими руками.
- **Кодирование строк:** от простых категорий до продвинутых техник.
- **Польза из мусора:** как превратить «шум» в прирост метрики.