Математические основы ML

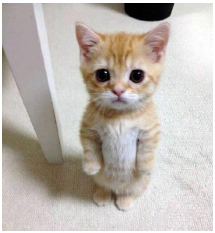
Reading Group

От реального мира к таблице

Как описать объект языком математики? Измерить его характеристики (**признаки**):

Объект	**Длина усов** (x_1, см)	**Цвет глаз** (x_2, категор.)	**Порода** (x_3, категор.)	**Рост** (x_4, см)	**Длина хвоста** (y) **(таргет, см)**
Котик 1 (Барсик)	7.5	Зеленый	Сибирская	28	30.0
Котик 2 (Мурзик)	6.0	Голубой	Сиамская	24	25.5
Котик 3 (Снежок)	8.2	Желтый	Мейн-кун	35	38.0
...	...	...	...	...	...
Котик N (Новый)	7.0	Зеленый	Британская	26	**???**

- **Строки ($i = 1, \ldots, N$):** объекты выборки (конкретные котики).
- **Столбцы ($x_1, \ldots, x_d$):** признаки.
- **Целевая переменная (y):** значение, которое мы хотим предсказать.



Постановка задачи

Обучающая выборка: $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}, \quad x_i \in \mathbb{R}^d, \quad y_i \in \mathbb{R}$

Матрица «объекты-признаки» и вектор целевой переменной:

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{Nd} \end{pmatrix} \in \mathbb{R}^{N \times d}, \qquad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} \in \mathbb{R}^N$$

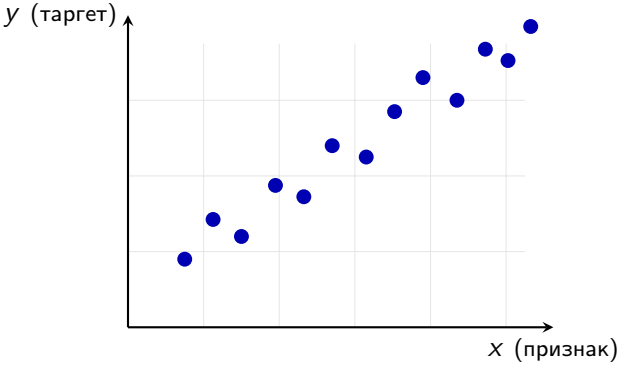
Базовая вероятностная предпосылка (i.i.d.) Наблюдения независимы и одинаково распределены:

$$(x_i, y_i) \overset{\text{i.i.d.}}{\sim} \mathcal{P}(X, Y)$$

Цель обучения

Найти отображение $\hat{f}\colon \mathbb{R}^d \to \mathbb{R}$, приближающее истинную зависимость $y = f(x) + \varepsilon$.

Двумерный случай: наблюдения на плоскости



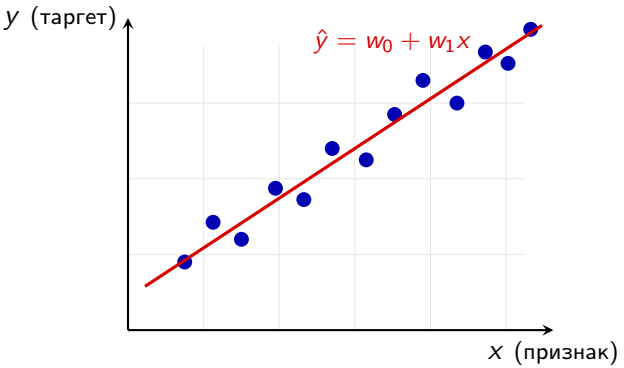
Геометрический взгляд:

- Представим простейший случай: один признак x и один таргет y.
- Каждая точка (x_i, y_i) — это отдельный объект выборки.
- Виден общий тренд, но из-за шума ε точки не лежат на строгой кривой.

Главный вопрос

Как математически обобщить эту зависимость и делать предсказания?

Самая простая идея: провести прямую



Линейная модель:

- Самое естественное решение — провести усредняющую **прямую линию**.
- Формула прямой:

$$\hat{y} = w_0 + w_1 x$$

- w_0 — сдвиг (bias).
- w_1 — наклон (вес признака).

Линейная модель в d-мерном пространстве

Аналитическая форма:

$$\hat{y}(x) = w_0 + \sum_{j=1}^{d} w_j x_j$$

- $x = (x_1, \ldots, x_d)$ — вектор признаков объекта
- $w = (w_1, \ldots, w_d)$ — веса (коэффициенты модели)
- w_0 — свободный коэффициент (**bias** / сдвиг)

Векторная запись:

$$\hat{y}(x) = w_0 + w^T x$$

Почему в формуле пишется $w^T x$?

Соглашение линейной алгебры: векторы по умолчанию — **столбцы**:

$$w \in \mathbb{R}^{d \times 1}, \qquad x \in \mathbb{R}^{d \times 1}$$

Произведение двух столбцов $(d \times 1) \times (d \times 1)$ не определено.

Транспонирование превращает столбец в вектор-строку:

$$w^T \in \mathbb{R}^{1 \times d}$$

Согласование размерностей

$$\underbrace{w^T}_{1 \times d} \cdot \underbrace{x}_{d \times 1} = \langle w, x \rangle = \sum_{j=1}^{d} w_j x_j \in \mathbb{R} \quad \text{(скаляр)}$$

Векторизация через фиктивную единицу

Идея: спрятать сдвиг w_0 внутрь вектора весов.

Добавим к признакам фиктивную константу $x_0 \equiv 1$:

$$\tilde{x} = \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_d \end{pmatrix} \in \mathbb{R}^{d+1}, \qquad \tilde{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{pmatrix} \in \mathbb{R}^{d+1}$$

Единый векторный вид

$$\hat{y}(x) = \tilde{w}^T \tilde{x} = w_0 \cdot 1 + w^T x$$

Матричный вид предсказания

Распространяем модель сразу на всю выборку из N объектов.

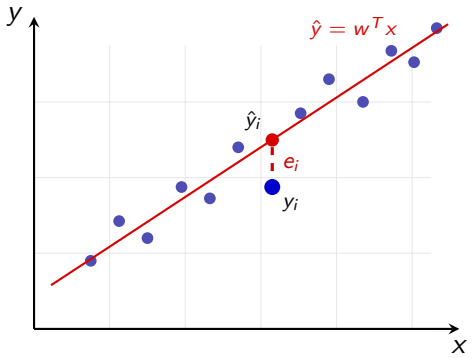
К матрице данных X слева добавляется столбец единиц:

$$X \in \mathbb{R}^{N \times (d+1)}, \qquad \tilde{w} \in \mathbb{R}^{(d+1) \times 1}$$

Предсказание для всех объектов

$$\hat{y} = X\tilde{w} \in \mathbb{R}^N$$

Как измерить ошибку для одной точки?



Ошибка для объекта x_i:

- y_i — истинное значение
- $\hat{y}_i = x_i^T w$ — прогноз модели
- $e_i = y_i - \hat{y}_i$ — невязка (остаток)

Квадратичная ошибка (L_2-loss)

$$\ell(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$$

Функция потерь на всей выборке (MSE)

Идея: усреднить квадраты ошибок по всем N объектам.

Mean Squared Error (MSE)

$$\mathcal{L}(w) = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 = \frac{1}{N}\|Xw - y\|_2^2$$

- $\mathcal{L}(w)$ — функция потерь (**Loss Function**).
- Скалярная величина: дает единую числовую оценку качества модели.
- Зависит только от вектора весов w (данные X и y фиксированы).

Задача безусловной оптимизации

Обучение линейной модели формализуется как математическая задача поиска минимума:

Постановка задачи

$$w^* = \arg \min_{w \in \mathbb{R}^{d+1}} \mathcal{L}(w)$$

- **Цель:** найти вектор оптимальных весов w^*, минимизирующий суммарную ошибку $\mathcal{L}(w)$.

Оценки как решение вариационных задач:

- **Выборочное среднее (L_2-оптимум, чувствительно к выбросам):**

$$\mu = \arg\min_c \sum_{i=1}^{N} (y_i - c)^2 = \frac{1}{N} \sum_{i=1}^{N} y_i$$

- **Медиана (L_1-робастный оптимум):**

$$\text{Med}(y) = \arg\min_c \sum_{i=1}^{N} |y_i - c|$$

Меры центра: устойчивость к выбросам

Пример: расходы 5 пациентов палаты на базовые препараты (тыс. руб.):

Выборка без аномалий:

$$\{2,\ 3,\ 4,\ 5,\ 6\}$$

- **Медиана** (L_1): $\text{Med} = 4$
- **Среднее** (L_2): $\mu = \frac{20}{5} = 4$

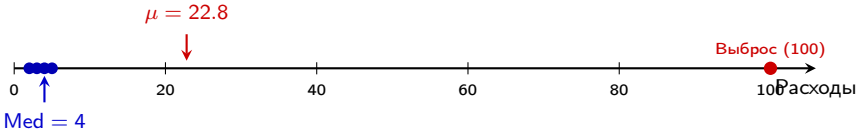
Оценки совпадают, центр очевиден.

Появился выброс (операция):

$$\{2,\ 3,\ 4,\ 5,\ 100\}$$

- **Медиана** (L_1): $\text{Med} = 4$ (не изменилась!)
- **Среднее** (L_2): $\mu = \frac{114}{5} = 22.8$ (сдвиг $\times 5.7$)

Среднее 22.8 не описывает никого.



Выборочная дисперсия

Определение дисперсии целевой переменной:

$$\text{Var}(y) = \sigma_y^2 = \frac{1}{N}\sum_{i=1}^{N}(y_i - \mu_y)^2$$

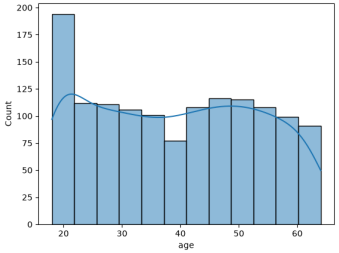
Стандартное отклонение: $\sigma_y = \sqrt{\text{Var}(y)}$

Связь с функцией потерь

Дисперсия $\text{Var}(y)$ тождественно равна среднеквадратичной ошибке наивного константного прогноза $\hat{y}_i = \mu_y$:

$$\text{Var}(y) \equiv \text{MSE}(\hat{y} = \mu)$$

Равномерное распределение: признак age



Распределение возраста в датасете

Модель: $X \sim \mathcal{U}[a, b]$

$$p(x) = \frac{1}{b-a}, \quad x \in [18; 64], \quad \mathbb{E}[X] = \frac{a+b}{2}$$

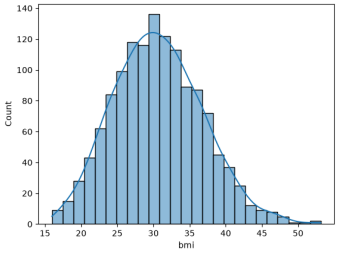
Природа в данных:

- Случайная сбалансированная выборка.
- Вероятность встретить клиента любого возраста примерно одинакова.

Значение для ML

- Нет дефицита данных на отдельных интервалах.
- Полное отсутствие выбросов (значения строго ограничены диапазоном $[a; b]$).

Нормальное распределение Гаусса: признак `bmi`



Симметричный колокол Гаусса

Плотность: $X \sim \mathcal{N}(\mu, \sigma^2)$

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Природа (ЦПТ): сумма сотен независимых факторов (генетика, сон, рацион). Центр: $\mu \approx 30$.

Почему Гауссиана идеальна для ML?

Среднее = Медиана = Мода — центр без смещения.

Центральная Предельная Теорема (ЦПТ): интуиция

Суть теоремы простыми словами:

*Сумма (или среднее) большого числа независимых случайных величин стремится к **нормальному распределению**, независимо от того, какими были исходные законы.*

Мысленный эксперимент: игральные кости

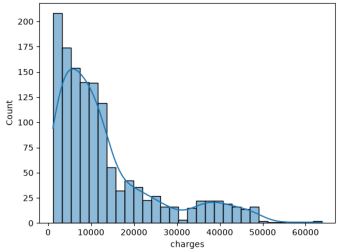
- **1 кубик:** равномерное ($p = \frac{1}{6}$).
- **2 кубика:** сумма 7 встречается чаще всего (треугольник).
- **10 кубиков:** сумма образует гладкий симметричный **колокол Гаусса**.

Почему крайности редки?

Чтобы получить минимум или максимум, **все** слагаемые должны одновременно выпасть в крайность.

В большинстве случаев плюсы и минусы взаимно компенсируются около центра.

Распределение с правым хвостом: таргет `charges`



Асимметричное распределение с длинным хвостом

Почему расходы всегда выглядят так?

- **Жесткая граница снизу:** чек не может быть отрицательным ($y \geq 0$).
- **Типичный случай:** большинство людей обращаются редко и тратят мало (пик слева).
- **Редкие катастрофы:** единичные сложные операции или тяжелые болезни создают чеки в десятки тысяч долларов, вытягивая длинный хвост вправо.

Почему это проблема для модели?

- Среднее $\gg$ Медиана: редкие гигантские чеки утягивают среднее далеко вправо.
- **Квадратичный штраф MSE:** колоссальная ошибка на хвосте заставляет прямую задираться вверх, завышая прогноз для большинства обычных людей.

Стандартизация признаков (Z-score)

Формула центрирования и масштабирования:

$$\tilde{x}_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \qquad \tilde{y}_i = \frac{y_i - \mu_y}{\sigma_y}$$

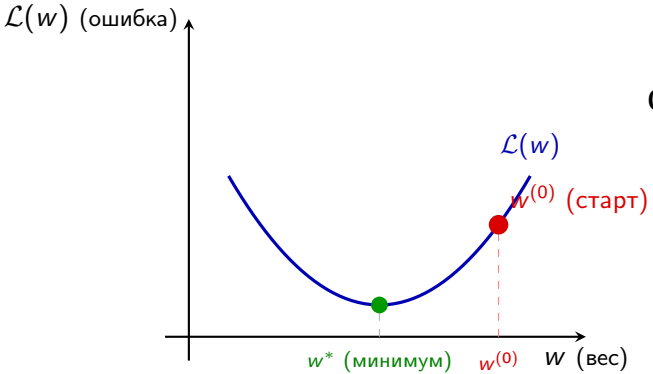
где $\mu_j = \frac{1}{N}\sum_i x_{ij}$, $\sigma_j^2 = \frac{1}{N}\sum_i (x_{ij} - \mu_j)^2$.

Свойства стандартизированных величин

$$\mathbb{E}[\tilde{x}_j] = 0, \qquad \mathrm{Var}(\tilde{x}_j) = 1$$

Устраняет влияние единиц измерения и обеспечивает сопоставимость весов w_j.

Ландшафт ошибки: где мы находимся?



Одномерный случай (один вес):

- Ось X — значение веса модели w.
- Ось Y — значение функции потерь $\mathcal{L}(w)$.
- **Красная точка** — наш случайный старт.
- **Зеленая точка** — оптимум w^*, где ошибка минимальна.

Что такое частная производная?

Обычная производная (одна переменная): Показывает скорость изменения функции: $f'(x) = \frac{df}{dx}$. Куда и с какой скоростью меняется f, если сдвинуть x?

Когда переменных много ($w_0, w_1, \ldots, w_d$): Функция потерь $\mathcal{L}(w)$ зависит от целого набора весов. Мы не можем сдвинуть «все сразу» одной производной.

Определение частной производной $\frac{\partial \mathcal{L}}{\partial w_j}$

Скорость изменения ошибки при изменении **только одного веса** w_j, когда **все остальные веса зафиксированы** (считаются константами):

$$\frac{\partial \mathcal{L}}{\partial w_j} = \lim_{\Delta w_j \to 0} \frac{\mathcal{L}(\ldots, w_j + \Delta w_j, \ldots) - \mathcal{L}(\ldots, w_j, \ldots)}{\Delta w_j}$$

Градиент: объединение производных в вектор

Вектор градиента $\nabla \mathcal{L}(w)$

Вектор-столбец, объединяющий частные производные по всем весам:

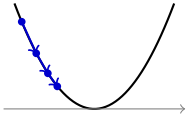
$$\nabla \mathcal{L}(w) = \begin{pmatrix} \frac{\partial \mathcal{L}}{\partial w_0} \\ \frac{\partial \mathcal{L}}{\partial w_1} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial w_d} \end{pmatrix} \in \mathbb{R}^{(d+1)\times 1}$$

Геометрический смысл градиента:

- Вектор $\nabla \mathcal{L}(w)$ указывает направление **наискорейшего роста** функции потерь.
- **Антиградиент** $-\nabla \mathcal{L}(w)$ указывает направление **наискорейшего убывания** (спуска к минимуму ошибки).
- Шаг оптимизации: $w^{(t+1)} = w^{(t)} - \eta \nabla \mathcal{L}(w^{(t)})$.

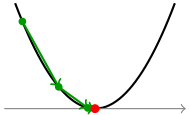
Скорость обучения (Learning Rate η)

Малый η



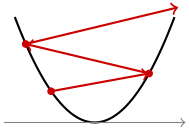
Ползет очень долго

Оптимальный η



Быстрый оптимум

Большой η



Перепрыгивает и растет

Правило обновления весов

$w^{(t+1)} = w^{(t)} - \eta \nabla \mathcal{L}(w^{(t)})$ — параметр η управляет компромиссом между стабильностью и скоростью обучения.

Градиент MSE: скалярный (поэлементный) вид

Функция потерь: $\mathcal{L}(w) = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$, где $\hat{y}_i = \sum_{k=0}^{d} w_k x_{ik}$.

Найдем производную по одному выбранному весу w_j по **правилу сложной функции**:

$$\frac{\partial \mathcal{L}}{\partial w_j} = \frac{1}{N}\sum_{i=1}^{N} \underbrace{2(y_i - \hat{y}_i)}_{\text{внешняя}} \cdot \underbrace{(-x_{ij})}_{\text{внутренняя}}$$

Формула для j-й компоненты градиента

$$\frac{\partial \mathcal{L}}{\partial w_j} = \frac{2}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)x_{ij} = \frac{2}{N}\sum_{i=1}^{N} \underbrace{e_i}_{\text{ошибка}} \cdot \underbrace{x_{ij}}_{\text{признак}}$$

Градиент MSE: матричный вид (векторизация)

Суммирование по N объектам и $d+1$ признакам можно записать в матричной форме.

Обозначим вектор ошибок выборки: $e = \hat{y} - y = Xw - y \in \mathbb{R}^{N\times 1}$.

Компактная матричная формула

$$\nabla \mathcal{L}(w) = \frac{2}{N} X^T (Xw - y) \in \mathbb{R}^{(d+1)\times 1}$$

Согласование размерностей:

$$\underbrace{X^T}_{(d+1)\times N} \cdot \underbrace{(Xw - y)}_{N\times 1} = \underbrace{\nabla \mathcal{L}(w)}_{(d+1)\times 1}$$

Метрики точности регрессии

- **Mean Absolute Error (L_1-норма):**

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

Робастна к выбросам, измеряется в единицах целевой переменной.

- **Mean Squared Error (L_2-норма):**

$$\text{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \quad [\text{ед.}^2]$$

Квадратично штрафует за единичные крупные ошибки.

- **Root Mean Squared Error:**

$$\text{RMSE} = \sqrt{\text{MSE}} \quad [\text{ед.}]$$

Главные выводы

- **Природа данных и ЦПТ:** сумма множества независимых факторов формирует симметричный колокол Гаусса (честное среднее, предсказуемые границы), а редкие специфические риски дают асимметричный тяжелый хвост.
- **Чувствительность к выбросам:** из-за квадрата в MSE единичные гигантские значения стягивают прямую регрессии на себя, ухудшая прогноз для большинства типичных наблюдений.
- **Градиентный спуск:** вектор частных производных указывает направление роста ошибки; двигаясь по антиградиенту с подобранным шагом η, мы итеративно находим дно чаши потерь.

Вопросы на закрепление

- **Меры центрирования:** Почему у целевой переменной среднее превышает медиану и чем для нас плохо распределение с правым хвостом?
- **Природа ЦПТ:** Почему сумма очков на 10 кубиках образует симметричный колокол Гаусса, хотя каждый отдельный кубик распределен строго равномерно?
- **Поведение оптимизатора:** Что геометрически происходит на графике функции потерь, если задать слишком большой шаг обучения η?